

Одинаковые данные, разные способы обработки

Python • pandas • SQLite | Apple M3, 16 GB RAM | 1 октября 2026

Реальные замеры на детерминированных synthetic-данных. 36 пилотных и 270 основных прогонов: три размера, три операции, cold/warm и пять повторов. Все результаты точно совпали с эталоном; шесть тестов корректности прошли.

Медианы на миллионе строк, мс

Операция	Режим	Python	pandas	SQLite
Фильтр	cold	223,09	27,94	509,94
Группировка	cold	173,93	17,51	815,28
JOIN + агрегация	cold	204,47	45,89	767,63
Фильтр	warm	27,55	17,68	64,07
Группировка	warm	72,13	6,62	380,16
JOIN + агрегация	warm	107,68	28,05	317,70

На миллионе строк pandas быстрее Python по медиане warm-времени в 1,56, 10,89 и 3,84 раза для фильтра, группировки и JOIN соответственно.

На 50 тыс. строк warm-фильтр быстрее у Python: 1,13 против 1,35 мс. С загрузкой и подготовкой быстрее pandas: 3,42 против 9,94 мс. Граница таймера меняет порядок именно в этом случае.

Для warm-JOIN peak RSS у SQLite равен 128,91 MiB против 229,83 MiB у pandas, но время SQLite больше. Это различие между временем и памятью, а не единый рейтинг эффективности.

Границы измерения и ограничения

Cold включает чтение, подготовку и полный ответ; импорт и запуск процесса исключены. Warm включает операцию и полный ответ после прогрева. Кеш ОС не очищался. Peak RSS охватывает весь процесс до проверки ответа, включая библиотеки, исходные данные и подготовку.

Одна машина, пять повторов, целочисленная схема без null и строк. Системный loadavg за минуту: 4,17-5,24; фон и температура не изолированы. SQLite threads=1 допускает один вспомогательный поток. На графиках все повторы и наблюдаемый минимум/максимум, не доверительные интервалы.

Работа процессов: 90,20 с; максимальный RSS: 282,08 MiB. Энергия не измерялась, выводов о CO2 нет. Источники в архиве: results/main/raw.csv, results/analysis/summary.csv; методика и воспроизводимый код включены. Следующие две страницы: все измеренные условия.

Elapsed time

Synthetic integer workload | One machine | Apple M3 MacBook Air, 16 GB RAM
5 independent repeats per cell | 270 measured runs | Same source data and exact result checks

● Python loops ■ pandas ▲ SQLite Small marks: individual runs Large marks: median Bars: observed min-max




Bars show the observed minimum and maximum, not confidence intervals. Dataset sizes are equally spaced categories.
Time y-axis limits differ between cold and warm rows; they are shared across operations within each mode.
Cold time includes loading, backend preparation and query output. Warm time includes only the query and its complete output.
RSS is the peak of the whole worker through query completion: imports, source data, backend setup and warm priming included.
Process-cold is not disk-cold; OS file cache was not cleared. One machine, one synthetic schema. No energy or CO2 measurement.

Peak whole-worker memory

Synthetic integer workload | One machine | Apple M3 MacBook Air, 16 GB RAM
5 independent repeats per cell | 270 measured runs | Same source data and exact result checks

● Python loops ■ pandas ▲ SQLite Small marks: individual runs Large marks: median Bars: observed min-max



Bars show the observed minimum and maximum, not confidence intervals. Dataset sizes are equally spaced categories.

Memory uses the same zero-based y-axis across all six panels.

Cold time includes loading, backend preparation and query output. Warm time includes only the query and its complete output.

RSS is the peak of the whole worker through query completion: imports, source data, backend setup and warm priming included.

Process-cold is not disk-cold; OS file cache was not cleared. One machine, one synthetic schema. No energy or CO2 measurement.